


Palantir AIP 架构详解

基于官方架构文档整理，重点呈现决策中心化设计与 Ontology 核心地位。

核对日期：2026-09-23。文中的产品状态与模型清单是官方公开文档及公告的时间点记录，具体可用性仍取决于 enrollment、区域与配置；“定位解读”“设计动机解读”属于作者分析。

1. 整体平台架构

Palantir 标准架构由三大平台构成，共同形成企业操作系统。



平台职责说明

平台	核心职责
Apollo	持续交付、零信任基础设施、Rubix 计算网络管理
Foundry	数据连接与转换、逻辑编写、工作流与分析
AIP	Secure LLM 接入、智能体生命周期、人机协同应用、评估框架

平台	核心职责
Ontology	决策中心，统一整合数据、逻辑、行动与安全

官方能力分层

官方将 AIP + Foundry 的能力进一步归纳为 **九大能力集**，由六个网格级组件横向支撑：

- **Ontology 系统**：Ontology Language + Ontology Engine + Ontology Toolchain
- **服务层**：Data Services（数据服务）+ Logic Services（逻辑服务）+ Workflow Services（工作流服务）
- **用户层**：Analytics & Applications（分析与应用）+ Automations（自动化）+ Product Delivery（产品交付工具链）
- **六网格组件**：Storage（存储）、Compute（计算）、Networking（网络）、Security（安全）、Governance（治理）、Workspace（工作空间）——全部由 Apollo 驱动

这是 **AIP + Foundry 整体架构**的九类能力视角；AIP 架构专页另以 12 类能力概括 AIP 的端到端架构，包括安全模型接入、上下文工程、可观测性、智能体生命周期和产品交付等。

官方对三平台关系的定位是 **"Enterprise Operating System"（企业操作系统）**：


- AIP + Foundry 运行在同一服务网格（service mesh）中；
- Apollo 负责编排数千次零停机升级。

2. Ontology 系统三层结构

Ontology 是整个架构的决策中心，并非简单语义层，而是完整的多模态系统。

官方原文直接印证了这一论断：

- 决策中心："*The Ontology is the system at the heart of Palantir's architecture... models the complex, interconnected **decisions** of an enterprise, not simply the data*".
- 非语义层：*"The Ontology is **not a 'semantic layer'**"*。
- 名词与动词：数据对象是"名词"（nouns），必须有"行动"（verbs）与之配对——语义必须与动力学（kinetics）结合，"*semantics must be paired with kinetics*".



四要素横向支撑


Data (数据) + Logic (逻辑) + Action (行动) + Security (安全)

- **Data**: 将异构数据源统一映射为业务对象、属性与链接。
- **Logic**: 业务规则、机器学习模型、优化器及 LLM 驱动函数。
- **Action**: 从简单事务到多步骤工作流，可写回运营与边缘系统。
- **Security**: 角色、标记与用途的细粒度动态访问控制，对人类与智能体统一生效。

决策图与学习回路

- **decision graph (决策图)**: 每条逻辑（简单规则或复杂编排）可连接到每个行动，把传统上碎片化的流程串成一张图。
- **continuous learning loops (持续学习回路)**: 工作流中的每一条反馈都被安全地纳入学习回路，支撑从"增强"到"自动化"的演进。
- **cybernetic enterprise (控制论企业)**: 官方原文对 Ontology 作为动态、复利式数字核心的定位。

3. 端到端决策闭环（受控人审场景示意）



图示适用范围与设计原则


- 这是需要人审的工作流示例：智能体可先生成建议，再按配置经授权审批或策略检查后执行；不能据此推断所有 AIP 智能体都默认走提案模式。
- 执行结果与反馈可按应用设计记录或回写 Ontology，用于评估和改进；回写与持续优化不是无需配置的自动保证。
- 平台提供执行追踪、可观测性与审计能力，具体覆盖范围取决于采用的组件及 workflow 配置。

官方表述与产品化落地

- **演进路径：**官方将这一演进概括为 "*journey from augmentation to automation*"（从增强到自动化的旅程）——渐进自动化是官方设计语言，而非事后解释。

- **AI FDE 的默认分支流程**：AI FDE 默认使用分支，在 Global Branch proposal（全局分支提案）或 Code Repository PR 中提交相应变更供审查；变更操作还受用户批准、权限与平台审计约束。这是 AI FDE 的产品行为，不应推广成所有 AIP 智能体的统一默认流程。
- **可观测性**：官方对应能力为 AIP observability，基于 Workflow Lineage 提供指标、执行历史、**分布式追踪（distributed tracing）**、日志与日志检索，覆盖智能体链式执行的全链路。

4. 安全与治理三层结构




平台级访问控制同时适用于人类用户与 AI 智能体；智能体实际权限由调用用户或项目的权限配置等条件决定。

官方安全承诺与认证细节

- **基础设施层**：Rubix 为加固版 Kubernetes。
 - **节点与容器轮换**：Rubix 文档写明节点最长运行 48 小时；MMDP 文档写明容器在 72 小时内销毁并轮换。两处约束的对象不同。
 - **认证相关能力**：Rubix 文档描述其特性可满足包括 **FedRAMP High**、**DoD DISA IL-5/IL-6**、**CMMC** 在内的严苛认证标准；特定部署的认证状态仍须按授权范围核实。
 - **部署范围**：跨 AWS / Azure / GCP / Oracle Cloud / 本地环境，行为一致。
- **AIP 接入的第三方托管模型服务的数据承诺**：官方对这一接入路径说明——
 - 提示词与输出**不被第三方留存、不用于再训练、供应商人员无法访问**（Palantir 与模型提供商签有合同与技术双重保证）；
 - 模型请求在可用且可行时路由到区域端点（US / UK / EU 等）；这一说明不自动覆盖所有客户自接入模型的处理方式。
- **服务商认证**：官方称，除非 AIP 合同另有明确约定，已接入的第三方托管模型服务商获得 ISO 27017、SOC 1/2/3、CSA STAR 和 / 或其他认证；不应理解为每家服务商同时持有全部认证。

- **模型治理状态机**：模型系列在 Control Panel 中可处于 enabled / disabled / **disallowed** 状态。具体可用性取决于模型是否已集成、法律条款确认、AIP 功能启用、地理限制、必要的工程审查、面向具体 AIP 产品的接入进度，以及实验性模型的风险确认等条件。
- **地理分区示例**：模型可用性按 US / EU / UK / CA / AU / JP / KSA / **IL2 / IL4 / IL5（国防隔离区）** 分级。
 - 这是模型在不同 enrollment 中的可用性与治理约束，不能直接等同于 Ontology 的动态访问控制。

5. 简化总结视图



当前官方架构中心对 MMDP 的概括：

"Any data, any compute, any model, anywhere"（任意数据、任意计算、任意模型、任意地点）

该数据面理念由 **MMDP 多模态数据面** 承载——详见下文第 7 节。

6. 核心设计要点总结

1. **决策中心化**：Ontology 是架构核心，编码企业知识、规则与允许的行动。
2. **LLM 角色定位**：大语言模型作为可替换的推理组件，在 Ontology 约束下运行。
3. **提案与反馈闭环**：在需要人审的路径中，智能体可生成提案，经授权审核后执行；反馈可按工作流设计记录或用于优化。
4. **统一安全治理**：人类与智能体遵循平台统一的权限控制与审计机制，实际授权范围依用户或项目配置而定。

5. **渐进自动化**：支持从人机协同增强，到受控自主执行的平滑过渡。
6. **开放数据面 (MMDP)**：以 Apache Iceberg 开放格式、虚拟表与计算下推支持互操作；虚拟目录和虚拟表可使特定外部数据接入 Ontology 时免于重复复制。
7. **战略解读 (作者判断)**：Palantir 强调数据、计算、模型及 Ontology 接口的互操作，同时仍将 Ontology 置于架构核心。商业护城河的判断需与官方技术事实区分。
8. **模型无关的工程保障**："LLM 可替换"不是口号，由 AIP Evals 评估框架（测试用例 + 评估函数 + 跨模型对比 + 方差分析）提供工程支撑。

7. MMDP 多模态数据面

MMDP (Multimodal Data Plane) 是 Palantir 的开放数据与计算架构，哲学口号：

"Any data, any compute, any model, anywhere."

开放数据架构

- 以 **Apache Iceberg** 为 Foundry / AIP 主表格式 (AWS、GCP、Azure、Databricks、Snowflake 同为生态伙伴)。2026-09-15 公告宣布托管 Iceberg 表及 Palantir Iceberg REST catalog 在 AWS / Azure / GCP 托管的标准 Foundry 企业环境中 GA；这不等于所有部署环境均已启用。
- **Virtual Tables (虚拟表)**：Iceberg 目录可托管在 Palantir 内，也可注册 Databricks / Snowflake / BigQuery 等外部虚拟目录——Ontology 使用外部数据**无需复制**。
- 非表格数据 (媒体、文档、流式、地理空间) 同样开放：REST API + Python / TypeScript SDK 访问；导出任务与 Ontology webhook 同步到外部系统。

开放计算架构

- 内置运行时：Spark (批)、Flink (流)、DataFusion / Polars / DuckDB (单节点)，全部跑在 Rubix 加固 Kubernetes 网络上。
- **Compute Modules (计算模块)**：BYO Compute——任何容器化资源 (遗留可执行程序、专用模型、自定义引擎) 可导入并在批/流/交互式函数中安全使用。
- **计算下推 (pushdown compute)**：Pipeline Builder、Code Workspaces 可直接使用客户现有的 Databricks / Snowflake 计算资源。

开放模型架构

- **Model Catalog**：OpenAI、Anthropic、Google (Gemini)、Meta (Llama)、xAI (Grok) 等最新模型，与客户自注册模型 (微调、自有、遗留) 同场竞技。
- 有趣细节：嵌入模型目录包含 **Snowflake Arctic Embed**——Palantir 与"竞争对手"的模型同目录提供。

- 模型访问可按用途精确治理（token 限额等）。

定位解读（作者判断）

从公开架构资料可以作如下解读：

- Palantir 强调数据、计算、模型的开放标准与互操作能力，但各功能仍有接入和部署条件；
- **Ontology** 仍是架构核心，同时其元素可通过 REST API、JSON 配置、OSDK 与 MCP 等接口连接外部系统；
- “护城河在决策中枢”属于商业分析，不是官方文档给出的技术边界。

8. 互操作性六大类

官方架构中心专设 Interoperability 章节，Palantir 与既有企业软件栈的互操作分为六类；Palantir MCP 被列在语义互操作之下：

互操作类型	关键机制
数据	原始格式存储（CSV / Iceberg / Parquet）；REST / JDBC / S3 接口；Virtual Tables 免复制接入 Databricks / Snowflake / BigQuery；HyperAuto 自动生成数据管道
元数据	血缘、标签、安全标记等全量元数据经 Platform SDK / REST 暴露，可对接外部数据目录与元数据管理工具
语义	Ontology 元素（对象/链接/行动/函数）可经 REST API 访问并通过 JSON 驱动的方式配置，支持与外部语义建模工具双向同步；Palantir MCP 支持智能体驱动的语义互操作
代码与逻辑	Python / Java / SparkSQL 等开放语言；Spark / Flink / DataFusion / Polars 开放运行时；ONNX 模型格式；Code Repositories 基于高可用 Git 服务
分析	Power BI、Tableau、Jupyter、RStudio 官方连接器；Code Workspaces 原生嵌入 Jupyter / RStudio
安全	SAML 认证、Active Directory 授权；权限经 Ontology SDK 扩展至第三方应用

解读：Palantir 为互操作提供了具体机制；其对“封闭黑盒”印象的影响属于作者判断。

9. 智能体产品矩阵

截至 2026-09-23 的智能体与 AI 应用相关产品节选。表中状态来自官方文档或带日期的公告，不代表每个 enrollment 均已启用：

产品	定位	状态
AIP Chatbot Studio (原 AIP Agent Studio)	构建交互式助手 (AIP Chatbots), 可部署于平台内或经 OSDK / API 外部部署; 内置企业数据与工具	原产品 2025-05 起 GA; 2026-04 更名
AIP Logic	无代码 LLM 函数开发环境: 块 (Blocks) 链式组合, 可读写 Ontology; 发布后经 Action 调用	稳定
AIP Evals	评估框架五件套: Evaluation suite / target function / evaluation function / test cases / metrics; 支持跨模型对比与方差分析; 已集成进 AI FDE	稳定
AI FDE (AI 驻场工程师)	对话式操作 Foundry: 建管道、改 Ontology、写函数、配置 Automate、建 OSDK 应用、审计权限	2026-03 宣布 GA ; Automate 工具于 2026-08 公告
AIP Evolve	协调多个 AI FDE 智能体, 在指定目标、验证策略与变更约束下改进 AI 系统, 提交结果和证据供审查	2026-09-08 宣布 GA
AIP Analyst	自然语言对 Ontology 做即席分析: 搜索 → 对象集 → 聚合 → 可视化; 可嵌入 Workshop / iframe	2026-04 起 GA
AIP Assist	平台内 LLM 帮助助手; 默认不读取用户正在处理的数据, 可按管理员配置使用自定义内容源或 AIP Chatbots 模式	稳定
AIP Threads	拖拽文档即用的轻量 LLM 交互 (无需技术配置)	2024-10 宣布 beta; 当前是否 GA 未核实
AIP Document Intelligence	比较文档提取策略的质量、速度和成本, 并将策略部署到 Python transforms 或 functions	应用 2026-02 宣布 GA; functions 部署 2026-07 宣布 GA
Autopilot	通过看板、依赖图、自动化事件与对象追踪管理 Ontology 自动化工作流	2026-03 公告为 beta; 现已有 官方文档 , 当前是否 GA 未见明确公告

AI FDE 的四个设计要点 (官方文档)

- "Context pollution" 治理:** 初始状态仅加载最小上下文 (不含用户数据), 由用户拖拽扩权——最小权限原则在 LLM 时代的工程化。
- Closed-loop 操作模型:** 执行 → 观察结果 → 反馈决定下一步; 自带验证 (transform preview、function preview、CI 检查)。
- 默认分支提案:** AI FDE 默认使用分支, 把相应改动提交为 Global Branch proposal 或 Code Repository PR 供审查; 写入操作仍须符合权限与用户批准规则。
- 模型支持:** Anthropic / OpenAI / Google / xAI, 原生工具调用 (native tool calling)。

MCP 双轨制（重要）

	Palantir MCP（构建者）	Ontology MCP / OMCP（消费者）
使用者	AI IDE / 智能体（Claude Code、VS Code Continue 等）	外部 AI 客户端（Copilot Studio、Gemini Enterprise 等）；可用于 Teams 等工作环境中的智能体场景
能力	导航 Foundry 架构、搜 Ontology、 修改 ontology 类型 、预览/修复 transforms	将 object types / action types / query functions 暴露为 MCP 工具， 读写 Ontology 数据
边界	可改类型， 不能写数据	经 application restrictions 限制智能体可触发的行动
生态	—	MCP Hub 可发现/管理 OMCP 服务；官方文档以 Copilot Studio 智能体在 Microsoft Teams 中使用 Ontology 为示例，不等同于承诺所有 Teams 环境均有原生集成

作者解读：Ontology MCP 使外部 AI 平台能在配置的权限和 application restrictions 内读取 Ontology 数据、查询并执行预定义行动，“决策中心”由此可参与跨平台工作流。

10. 模型生态与治理

官方公开模型清单节选（核对日期：2026-09-23）

型号与可用区域变化很快；以下是 Palantir [Supported LLMs](#) 页面和近期公告中的节选，不表示每种型号在所有 enrollment、区域或 AIP 产品入口均可使用。

- **xAI**：Grok-3 / Grok-4 / Grok-4-Fast / Grok-Code-Fast-1；地理可用性表还列出 Grok 4.3 / 4.5 等型号。
- **OpenAI**：GPT-4o / GPT-4.1 / GPT-5 至 GPT-5.5 的若干具体型号，以及 GPT-5.6 Luna / Sol / Terra；**GPT-5.3 Codex** 应按全名记录，不能简写为“GPT-5.3 全系”。
- **Anthropic**：Claude 3.5 / 3.7 / 4 的若干具体型号、Claude Opus 4.8、Claude Sonnet 5、Claude Opus 5；不同模型与提供商通道的地理可用性不同。
- **Google**：Gemini 2.0 / 2.5、Gemini 3 Flash、Gemini 3.1 Pro、Gemini 3.5 Flash / Flash-Lite、Gemini 3.6 / 3.7 Flash。当前支持清单未列“Gemini 3.5 Pro”。
- **开源及开放权重**：Llama 3 / 3.1 / 3.3 / 4、Mistral / Mixtral、Gemma 4 的部分型号。
- **嵌入**：ada embedding、text-embedding-3 系、Snowflake Arctic Embed。
- **音频**：GPT Realtime 1.5 / 2.0（流式语音对话）、Whisper、GPT-4o Transcribe（含说话人分离 diarization）

官方来源差异：[2026-09-10 公告](#)宣布 Gemini 3.8 Flash 已在指定环境提供，但核对当日的 Supported LLMs 页面尚未列出 3.8。引用该型号时应注明公告日期、适用环境和清单尚未同步，不能默默合并为“全区域已支持”。

模型接入路径

除 Palantir 托管接入外，还有三条路径：

- **BYO Model (bring-your-own-model)**：接入企业自有模型（订阅、微调、领域模型）。
- **自托管模型 (self-host)**：私有部署。
- **模型供应商兼容 API**。

另有 LLM 容量管理与速率限制治理。

术语考证

- **k-LLM**：官方平台概述页提及这一表述，[AIP Logic 文档](#)将其与在平台中使用可用的不同 LLM 联系起来。公开材料未给出可据此推断与 k-匿名有关的定义，因此不作词源或隐私机制推测。
- **轮换对象**：Rubix 页的 48 小时指节点，MMDP 页的 72 小时指容器；参见第 4 节。

11. 设计动机解读

以下是基于官方材料提出的作者分析，用于解释可能的设计动机；除特别指出的产品行为外，不应将动机判断视为 Palantir 官方结论：

1. 为什么决策必须中心化？

- 客户（国防、医疗、能源）需要的是可审计的 AI；
- Ontology 把每个决策的数据、逻辑、行动、权限绑成可回溯整体，审计日志才能回答“这个订单为什么被拒”。

2. 为什么 LLM 必须可替换？

- **合规**：AIP 接入的第三方托管模型服务有不留存数据、不用于再训练的公开承诺，其他接入路径须分别核对；
- **模型演进**：型号和可用性持续变化，见第 10 节的时间点记录；
- **议价权**：多模型选择可能增强采购弹性，这是作者的商业推断；
- **工程前提**：可用 AIP Evals 对候选模型运行测试用例、比较结果与方差，验证更换模型的实际影响。

3. 为什么在部分流程中使用提案模式？

- 官方原话 “*journey from augmentation to automation*”；
- 渐进自动化可让审核、权限和验证随 workflow 风险调整；
- AI FDE 的默认分支提案是一个产品化示例，但其他 AIP 工作流也可采用不同程度的自主执行。

4. 为什么强调互操作？

- 官方 MMDP 资料明确支持与现有数据湖、计算环境、模型和治理工具共存的混合架构；
 - Ontology 是架构核心，但其元素也可通过 REST API、JSON 配置、OSDK 与 MCP 等接口与外部系统连接；
 - 对“供应商锁定”或商业护城河的判断是作者解读，不能仅凭接口清单推出确定结论或“2026 年突然开放”的时间线。
-

12. 参考来源

架构中心

- 总览: <https://palantir.com/docs/foundry/architecture-center/overview/>
- Ontology 系统: <https://palantir.com/docs/foundry/architecture-center/ontology-system/>
- MMDP: <https://palantir.com/docs/foundry/architecture-center/multimodal-data-plane/>
- 互操作性: <https://palantir.com/docs/foundry/architecture-center/interoperability/>
- Rubix: <https://palantir.com/docs/foundry/architecture-center/rubix/>
- 三平台: <https://palantir.com/docs/foundry/architecture-center/platforms/>
- AIP 架构: <https://palantir.com/docs/foundry/architecture-center/aip-architecture/>

AIP 文档

- AIP 概览: <https://palantir.com/docs/foundry/aip/overview/>
- AIP 功能清单: <https://palantir.com/docs/foundry/aip/aip-features/>
- AIP 安全与隐私: <https://palantir.com/docs/foundry/aip/aip-security/>
- 支持模型清单: <https://palantir.com/docs/foundry/aip/supported-llms/>
- AIP Logic 核心概念: <https://palantir.com/docs/foundry/logic/core-concepts/>
- AIP Logic Blocks 与 k-LLM 表述: <https://palantir.com/docs/foundry/logic/blocks/>

智能体与应用

- AI FDE: <https://palantir.com/docs/foundry/ai-fde/overview/>
- AI FDE 安全与治理: <https://palantir.com/docs/foundry/ai-fde/security-and-governance/>
- AIP Evolve: <https://palantir.com/docs/foundry/aip-evolve/overview/>
- AIP Analyst: <https://palantir.com/docs/foundry/aip-analyst/overview/>
- AIP Chatbot Studio: <https://palantir.com/docs/foundry/chatbot-studio/overview/>
- AIP Document Intelligence: <https://palantir.com/docs/foundry/document-intelligence/overview/>
- AIP Evals: <https://palantir.com/docs/foundry/aip-evals/overview/>
- AIP Assist: <https://palantir.com/docs/foundry/assist/overview/>
- AIP Threads: <https://palantir.com/docs/foundry/threads/overview/>
- Autopilot: <https://palantir.com/docs/foundry/autopilot/overview/>
- Palantir MCP: <https://palantir.com/docs/foundry/palantir-mcp/overview/>

- Ontology MCP: <https://palantir.com/docs/foundry/ontology-mcp/overview/>
- Ontology MCP 使用示例: <https://palantir.com/docs/foundry/ontology-mcp/example-mcp-workflows/>

动态

- 2026 Release Notes: <https://palantir.com/docs/foundry/announcements/release-notes/>
- 2024-10 公告 (AIP Threads beta) : <https://palantir.com/docs/foundry/announcements/2024-10/>
- 2025-04 公告 (AIP Agent Studio GA 计划) : <https://palantir.com/docs/foundry/announcements/2025-04/>
- 2026-02 公告 (AIP Document Intelligence GA) : <https://palantir.com/docs/foundry/announcements/2026-02/>
- 2026-03 公告 (AI FDE、AIP Analyst、Autopilot) : <https://palantir.com/docs/foundry/announcements/2026-03/>
- 2026-07 公告 (AIP Document Intelligence functions 部署) : <https://palantir.com/docs/foundry/announcements/2026-07/>
- 2026-08 公告 (AI FDE Automate 工具) : <https://palantir.com/docs/foundry/announcements/2026-08/>
- 2026-09 公告 (AIP Evolve、Iceberg、模型) : <https://palantir.com/docs/foundry/announcements/2026-09/>

文档整理完成。内容基于 Palantir 官方架构说明重新组织，确保层级清晰、文字互不覆盖。